

课程实验一：云主机实现大数据

实验时间：2021 年 03 月 25 日

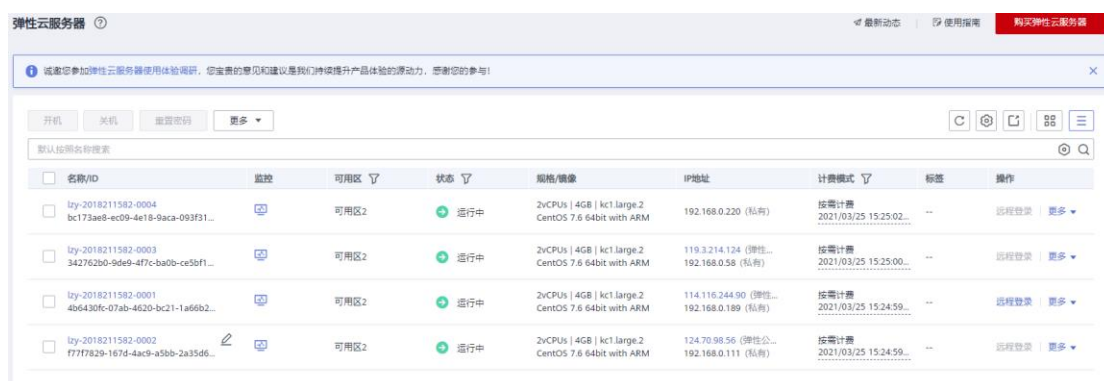
实验学生姓名：李志毅

学生班号、学号：2018211314 班 2018211582

一、实验步骤

请大家参照《云主机实现大数据实验指导书》完成本次实验，并将实验中的结果截图，完成本次实验报告。

1. “1.2 购买华为云 ECS” 中的步骤 6，要求自定义云服务器名称为 **“姓名+学号+节点序号 (1234)”**。



2. “2.2.1 配置 ECS” 中的步骤 1，使用 putty 连接成功后，在这里贴 node1 主机登录成功的命令行界面，必须要体现出**主机名和 IP 地址**

```
lzy-2018211582-0001
Xshell 6 (Build 0206)
Copyright (c) 2002 NetSarang Computer, Inc. All rights reserved.

Type 'help' to learn how to use Xshell prompt.
[C:\~]$

Connecting to 114.116.244.90:22...
Connection established.
To escape to local shell, press 'Ctrl+Alt+J'.

WARNING! The remote SSH server rejected X11 forwarding request.

Welcome to Huawei Cloud Service

[root@lzy-2018211582-0001 ~]#
```

个人理解：我这里选用的是 xshell 登录我的 node1 服务器，使用 xshell 可以和 xftp 搭配能够上传文件。我的 node1 服务器名字为 'lzy-2018211582-0001'，图示为登录成功后显示内容，公网 ip 114.116.244.90

3. “2.2.1 配置 ECS” 中的步骤 6 配置节点互信，在这里贴任意一个节点执行 ssh 命令跳转成功的截图，要体现出执行的命令和运行结果

```
[root@lzy-2018211582-0001 ~]# ssh lzy-2018211582-0002
The authenticity of host 'lzy-2018211582-0002 (192.168.0.111)' can't be established.
ECDSA key fingerprint is SHA256:X4CONqKLYc2rCCz9kMiwEImNCQDBnRdMIXV+NBgaWaA.
ECDSA key fingerprint is MD5:f9:8f:e3:de:8e:36:51:41:0d:d6:96:77:ce:05:e8:c3.
Are you sure you want to continue connecting (yes/no)? yes
Warning: Permanently added 'lzy-2018211582-0002,192.168.0.111' (ECDSA) to the list of known hosts.
Last login: Thu Mar 25 16:07:08 2021 from 59.64.129.1

Welcome to Huawei Cloud Service

[root@lzy-2018211582-0002 ~]#

[root@lzy-2018211582-0002 ~]# ssh lzy-2018211582-0003
The authenticity of host 'lzy-2018211582-0003 (192.168.0.58)' can't be established.
ECDSA key fingerprint is SHA256:z9t7wlqRAme6dKgWAtRSqX9kqI2EVPGR0BKrRV06UDs.
ECDSA key fingerprint is MD5:63:d6:80:07:2e:da:c1:73:69:42:67:6f:0b:76:2b:ab.
Are you sure you want to continue connecting (yes/no)? yes
Warning: Permanently added 'lzy-2018211582-0003,192.168.0.58' (ECDSA) to the list of known hosts.
Last login: Thu Mar 25 16:09:07 2021 from 59.64.129.1

Welcome to Huawei Cloud Service

[root@lzy-2018211582-0003 ~]# ssh lzy-2018211582-0004
The authenticity of host 'lzy-2018211582-0004 (192.168.0.220)' can't be established.
ECDSA key fingerprint is SHA256:poKsye79AVBh4UqAid5szoP0WamYwtT9F7ck6lbdihY.
ECDSA key fingerprint is MD5:a1:c3:25:0f:d2:ba:a3:e6:d2:32:e6:7c:a3:74:58:37.
Are you sure you want to continue connecting (yes/no)? yes
Warning: Permanently added 'lzy-2018211582-0004,192.168.0.220' (ECDSA) to the list of known hosts.
Last login: Thu Mar 25 16:10:42 2021 from 59.64.129.1

Welcome to Huawei Cloud Service
```

个人理解：配置 ssh 互信，使得四个节点之间可以无需密码即可 ssh 命令登录，为之后的 MapReduce 项目铺垫，这里展示了配置完成后的截图，如图所示，node1 节点 'lzy-2018211582-0001' 服务器执行命令 `ssh lzy-2018211582-0002` 后可直接登录到 'lzy-

2018211582-0002'，在 node2 节点上执行 `ssh lzy-2018211582-0003` 可直接登录到

node3 节点，node3 节点执行命令可直接登录到 node4 节点。

4. “2.2.2 安装 JDK” 中的步骤 5，在这里贴执行 “java -version” 命令后的结果，显示 Java 版本即安装成功

```
[root@lzy-2018211582-0001 ~]# java -version
openjdk version "1.8.0_232"
OpenJDK Runtime Environment (build 1.8.0_232-b09)
OpenJDK 64-Bit Server VM (build 25.232-b09, mixed mode)

[root@lzy-2018211582-0002 ~]# java -version
openjdk version "1.8.0_232"
OpenJDK Runtime Environment (build 1.8.0_232-b09)
OpenJDK 64-Bit Server VM (build 25.232-b09, mixed mode)

[root@lzy-2018211582-0003 ~]# java -version
openjdk version "1.8.0_232"
OpenJDK Runtime Environment (build 1.8.0_232-b09)
OpenJDK 64-Bit Server VM (build 25.232-b09, mixed mode)

[root@lzy-2018211582-0004 ~]# java -version
openjdk version "1.8.0_232"
OpenJDK Runtime Environment (build 1.8.0_232-b09)
OpenJDK 64-Bit Server VM (build 25.232-b09, mixed mode)
```

个人理解：解压 jdk 文件，配置环境变量 `java_home`，执行 `source` 命令使其生效后，

四个节点执行 `java -vesion` 后都显示 `openjdk version "1.8.0_232"`

5. “2.3.1 搭建 Hadoop 集群” 中的步骤 12、13，在这里贴执行启动 hdfs 与执行 hdfs 命令的结果，要体现出执行的命令和运行结果

```
[root@lzy-2018211582-0001 ~]# start-dfs.sh
21/03/25 18:43:15 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Starting namenodes on [lzy-2018211582-0001]
lzy-2018211582-0001: starting namenode, logging to /home/modules/hadoop-2.8.3/logs/hadoop-root-namenode-lzy-2018211582-0001.out
localhost: starting datanode, logging to /home/modules/hadoop-2.8.3/logs/hadoop-root-datanode-lzy-2018211582-0001.out
lzy-2018211582-0003: starting datanode, logging to /home/modules/hadoop-2.8.3/logs/hadoop-root-datanode-lzy-2018211582-0003.out
lzy-2018211582-0002: starting datanode, logging to /home/modules/hadoop-2.8.3/logs/hadoop-root-datanode-lzy-2018211582-0002.out
lzy-2018211582-0004: starting datanode, logging to /home/modules/hadoop-2.8.3/logs/hadoop-root-datanode-lzy-2018211582-0004.out
Starting secondary namenodes [lzy-2018211582-0001]
lzy-2018211582-0001: starting secondarynamenode, logging to /home/modules/hadoop-2.8.3/logs/hadoop-root-secondarynamenode-lzy-2018211582-0001.out
21/03/25 18:43:30 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable

[root@lzy-2018211582-0001 ~]# hdfs dfs -mkdir /bigdata
21/03/25 18:44:35 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
[root@lzy-2018211582-0001 ~]# hdfs dfs -ls /
21/03/25 18:44:45 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
Found 1 items
drwxr-xr-x  - root supergroup          0 2021-03-25 18:44 /bigdata
```

个人理解：启动 hdfs, node1 启动 namenode, node2、3、4 启动 datanode, hdfs 启动后, node1 执行 jps 可以看到 Jps、SecondaryNameNode、ResourceManager、NameNode, 其余三个节点执行 jps 可以看到 NodeManager、Jps、DataNode

执行 hdfs 命令 **hdfs dfs -mkdir/bigdata**, 在 hdfs 上创建 bigdata 文件夹, 执行 **hdfs dfs -ls** 可以查看到该文件夹已创建成功

6. “2.3.2 测试与 OBS 互联” 中, 要求上传的文件以自己的**学号+姓名**命名, 在这里贴上传成功后执行 hdfs 命令查看 OBS 文件的结果

```
[root@lzy-2018211582-0001 ~]# hdfs dfs -ls obs://obs-2018211582/
21/03/25 19:36:59 WARN util.NativeCodeLoader: Unable to load native-hadoop library for your platform... using builtin-java classes where applicable
21/03/25 19:36:59 INFO services.ObsClient: Storage[1]HTTP+XML[ObsClient]|||2021-03-25 19:36:59|2021-03-25 19:36:59|||0|
21/03/25 19:36:59 WARN services.ObsClient: [OBS SDK Version=3.20.2.1];[Endpoint=http://obs.cn-north-4.myhuaweicloud.com:80/];[Access Mode=Virtual Hostin
g]
21/03/25 19:36:59 INFO internal.RestStorageService: OkHttp cost 144 ms to apply http request
21/03/25 19:36:59 INFO internal.RestStorageService: Storage[1]HTTP+XML[performRequest]|||2021-03-25 19:36:59|2021-03-25 19:36:59|[responseCode: 200][r
equest-id: 00000178692C62BF640E5C52B9C50C4C]||0|
21/03/25 19:36:59 INFO services.ObsClient: Storage[1]HTTP+XML[headBucket]|||2021-03-25 19:36:59|2021-03-25 19:36:59|||0|
21/03/25 19:36:59 INFO services.ObsClient: ObsClient [headBucket] cost 182 ms
21/03/25 19:36:59 INFO log.AccessLogger: 2021-03-25 19:36:59 766|com.obs.services.ObsClient|init|111|Storage[1]HTTP+XML[ObsClient]|||2021-03-25 19:36:5
9|2021-03-25 19:36:59|||0|
2021-03-25 19:36:59 767|com.obs.services.ObsClient|init|130|[OBS SDK Version=3.20.2.1];[Endpoint=http://obs.cn-north-4.myhuaweicloud.com:80/];[Access M

Found 1 items
-rw-rw-rw- 1 root root 105 2021-03-25 19:35 obs://obs-2018211582/2018211582-李志毅.txt
```

个人理解：我的 obs 桶名为 “obs-2018211582”, 上传文件名为 “2018211582-李志毅.txt”, 上传完成执行 hdfs 命令查看桶内文件可以看到该文件已经上传成功, 在 OBS 中展示。

7. “3.3.1 测试 Hadoop 集群功能” 中, 步骤 2 的测试文件请同学们自定义文件内容, 要求**包含自己的姓名中英文, 且至少有一个单词的数量大于等于 2**, 在这里贴 wordcount 的结果

```
2018211582-李志毅 - 记事本
文件(F) 编辑(E) 格式(O) 查看(V) 帮助(H)
我是李志毅, 我的英文名是lizhiyi, I love play games, many many games. I want to play games all day.
```

```
[root@lzy-2018211582-0001 ~]# hdfs dfs -cat /output/part-r-00000
21/03/25 19:55:57 WARN util.NativeCodeLoader: Unable to load native-
all      1
day.     1
games    1
games,many      1
games.I 1
love     1
many     1
play     2
to       1
want     1
我是李志毅,我的英文名是lizhiyi,I      1
```

个人理解：事先编写好 txt 文档内容，包含我的中文名和文名，以及出现两次的单词“play”，执行 wordcount 命令后可以看到结果如上，其统计出 play 出现两次，其余单词一次。

8. 请同学们实验后一定按照“4 释放云服务器资源”中的说明完成 ECS 资源和 OBS 桶的释放，否则会继续计费



二、结果分析

1. `hdfs-site.xml` 中参数 `dfs.replication` 的含义是什么？为什么要设置为 3？

解: `hdfs-site.xml` 中的参数 `dfs.replication` 代表备份系数,即缺省的块复制数量,代指 `DataNode` 存储 `block` 的副本数量,默认是 3,此数不能大于集群的机器数,理论上 `replication` 值越大跑数速度越快,但是需要的存储空间也更多,默认选择 3 是因为 HDFS 采用一种称为机架感知的策略来改进数据的可靠性、可用性和网络带宽的利用率。在大多数情况下, HDFS 的副本系数是 3, HDFS 的存放策略是一个副本存放在本地机架节点上,另一个副本存放在同一机架的另一个节点上,第三个副本存放在在不同机架的节点上。这种策略减少了机架间的数据传输,提高了写操作的效率。机架错误的概率远比节点错误的概率小,所以这种策略不会对数据的可靠性和可用性造成影响。与此同时,因为数据只存在两个机架上,这种策略减少了读数据时需要的网络传输带宽。在这种策略下,副本并不是均匀地分布在机架上。这种策略在不损坏可靠性和读取性能的情况下,改善了写的性能。